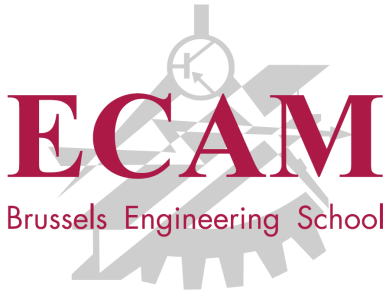

B216A Développement informatique

Expressions régulières

Sébastien Combéfis, Quentin Lurkin

Validation de données

- Important de valider les inputs

  Données entrées par le user, provenant de fichiers, du réseau...

- Formatage des données

  Via un parser qui produit une erreur en cas de format invalide

- Vérifier les données avec une expression régulière (module `re`)

  La donnée suit-elle un motif prédéfini ?

Exemple : Numéro de téléphone

- Numéro de téléphone de la forme xxxx/xx.xx.xx

Où les x sont des chiffres

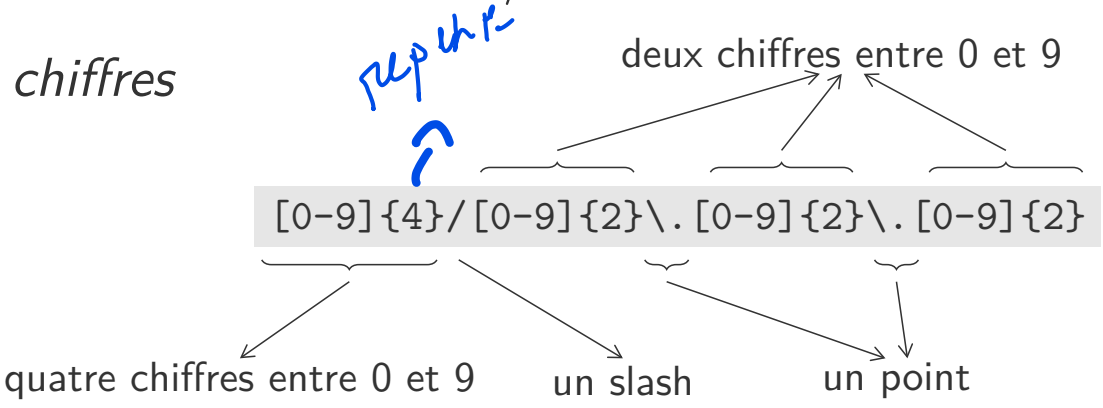


```
1  pattern = r'[0-9]{4}/[0-9]{2}\.[0-9]{2}\.[0-9]{2}'
2  p = re.compile(pattern)
3
4  print(p.match('0394/83.31.41'))
5  print(p.match('0394/83-31-41'))
```

```
<_sre.SRE_Match object; span=(0, 13), match='0394/83.31.41'>
None
```

Vérifier une chaine (1)

- Définition d'un motif représentant les chaines valides

  En utilisant une expression régulière

- Compilation du motif avec la fonction `re.compile`

  Renvoie un objet de type `regex`

- Vérification d'une chaine de caractères avec la méthode `match`

  Renvoie `None` si invalide, et un objet décrivant le match sinon

Description de motif (1)

- Précéder les méta-caractères avec un backslash

  `. ^ $ * + ? { } [ ] \ | ( )`

- Classes de caractères définies avec les `[ ]`

  `[abc]` : a, b ou c

  `[0-9]` : n'importe quoi entre 0 et 9

  `[a-zA-Z]` : n'importe quoi entre a et z ou entre A et Z

  `[^aeiou]` : n'importe quoi sauf a, e, i, o ou u

  `[a-z&&[^b]]` : intersection entre deux ensembles

- Classes prédéfinies de caractères

  `.` : n'importe quel caractère (sauf retour à la ligne)

  `\d` : un chiffre (équivalent à `[0-9]`)

  `\s` : un caractère blanc (équivalent à `[ \t\n\r\f\v]`)

  `\w` : un caractère alpha-numérique (équivalent à `[a-zA-Z0-9_]`)

Description de motif (2)

- Répétitions d'occurrences avec une quantificateur

  `{n}` : exactement *n* occurrences

  `{m,n}` : au moins *m* et au plus *n* occurrences

  `{m,}` : au moins *m* occurrences

  `{,n}` : au plus *n* occurrences

- Quantificateurs prédéfinis

  `?` = `{0,1}`

  `*` = `{0,}`

  `+` = `{1,}`

- Frontières de recherche

  `^` : début de la ligne

  `$` : fin de la ligne

Exemple : Nombre entier

- Nombre entier avec éventuellement un signe –

Le premier chiffre est non nul

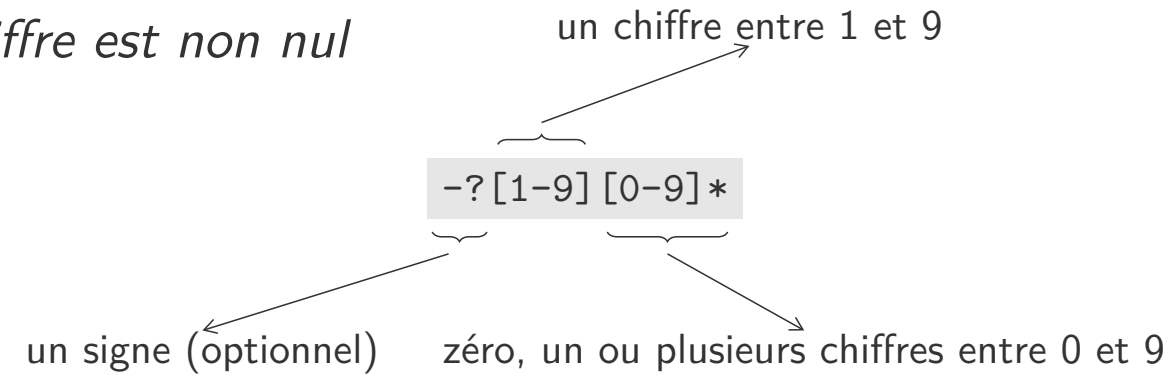


```
1  pattern = r'-?[1-9][0-9]*'
2  p = re.compile(pattern)
3
4  print(p.match('15') is not None)              # True
5  print(p.match('03') is not None)              # False
6  print(p.match('-7') is not None)              # True
7  print(p.match('-42') is not None)             # True
8
9  print(p.match('8 enfants !') is not None)     # True
```

Vérifier une chaine (2)

- Vérifier le contenu d'une chaine avec les frontières

  La méthode `match` cherche à partir du début de la chaine

- ^ matche le début de la chaine et $ la fin

  S'assure qu'une chaine complète suit un motif

```
1  pattern = r'-?[1-9][0-9]*'
2  p = re.compile(pattern)
3
4  print(p.match('8 enfants !') is not None)    # False
```

Options de compilation

- Flags à passer à la méthode `compile`

  Constantes définies dans le module `re`, à combiner avec `|`

Flag	Description
`re.IGNORECASE`	Recherche insensible à la casse
`re.DOTALL`	Le point matche également les retours à la ligne
`re.MULTILINE`	Les matches peuvent se faire sur plusieurs lignes

```
1 pattern = r'^[a-z]+$'
2 p = re.compile(pattern, re.IGNORECASE)
3
4 print(p.match('bogoss') is not None)  # True
5 print(p.match('LaTeX') is not None)   # True
```

La peste du backslash

- Utilisation recommandée des chaines brutes

  Sinon, de nombreux soucis avec le backslash

- Nom de commande LaTeX

Regex	Description
`\[a-zA-Z]+`	Nom d'une commande
`\\[a-zA-Z]+`	Échappement du `\` pour `compile`
`\\\\[a-zA-Z]+`	Construction d'un littéral `str`

```
1  p = re.compile('\\\\([a-zA-Z]+)')     # re.compile(r'\\([a-zA-Z]+)')
2  m = p.match('\\LaTeX')
3  if m is not None:
4      print(m.group(1))
```

Rechercher un motif (1)

- La méthode `match` renvoie un objet du match

  Plusieurs méthodes pour obtenir des informations sur le match

Méthode	Description
`group`	Renvoie la sous-chaine matchée
`start`	Renvoie la position du début du match
`end`	Renvoie la position de la fin du match
`span`	Renvoie un tuple avec les positions de début et de fin du match

```
1  pattern = r'\d+'
2  p = re.compile(pattern)
3
4  m = p.match('72 est égal à 70 + 2')
5  if m is not None:
6      print(m.group())       # 72
```

Rechercher un motif (2)

- `search` cherche un motif dans une chaine

  Recherche d'une sous-chaine qui matche le motif

- `findall` recherche toutes les sous-chaines qui matchent

  Renvoie une liste des sous-chaines matchées

```
1  pattern = r'\d+'
2  p = re.compile(pattern)
3
4  m = p.search('on sait que 72 est égal à 70 + 2')
5  if m is not None:
6      print(m.group())       # 72
7
8  print(p.findall('72 est égal à 70 + 2'))    # ['72', '70', '2']
```

Rechercher un motif (3)

- `finditer` renvoie un itérateur d'objets de match

  On peut ainsi parcourir les matchs avec une boucle `for`

```
1  pattern = r'\d+'
2  p = re.compile(pattern)
3
4  for m in p.finditer('on sait que 72 est égal à 70 + 2'):
5      print(m.span(), ':', m.group())
```

```
(12, 14) : 72
(26, 28) : 70
(31, 32) : 2
```

Choix

- Alternative entre plusieurs motifs avec |

  Représente l'opérateur « ou »

```
1  pattern = r'^[0-9]+|[a-z]+$'
2  p = re.compile(pattern)
3
4  print(p.match('283') is not None)
5  print(p.match('boat') is not None)
6  print(p.match('boat283') is not None)
```

```
True
True
False
```

Capturer des groupes

- Disséquer une chaine en sous-chaines matchantes

  Pouvoir extraire plusieurs parties d'une chaine donnée

- Définition de groupes dans le motif avec des ( )

  Chaque groupe représente un sous-motif

```
1  pattern = r'^([a-z]+)@([a-z]+)\.([a-z]{2,3})$'
2  p = re.compile(pattern)
3
4  m = p.match('email@example.net')
5  if m is not None:
6      print(m.groups())      # ('email', 'example', 'net')
7      print(m.group(1))      # email
```

Option de capture des groupes

- Option avec point d'interrogation après la parenthèse ouvrante

  Ce qui suit le ? décrit l'option

- Option spécifique à Python avec `(?P...)`

  Indique une option pas présente dans la syntaxe PERL

- Groupe non capturant avec l'option : `(d)`

  Permet d'appliquer un quantificateur sur un sous-motif

```
1  pattern = r'^(?:[0-9]+)$'
2  p = re.compile(pattern)
3
4  m = p.match('283')
5  if m is not None:
6      print(m.groups())          # ()
```

Groupe nommé

- Possibilité de nommer un groupe avec les options Python

Le groupe est récupéré avec son nom plutôt que sa position

```
1  pattern = r'^(?P<pseudo>[a-z]+)@(?P<domain>[a-z]+)\.(?P<extension>[
   a-z]{2,3})$'
2  p = re.compile(pattern)
3
4  m = p.match('email@example.net')
5  if m is not None:
6      print(m.groups())
7      print(m.group(1))
8      print(m.group('domain'))
```

```
('email', 'example', 'net')
email
example
```

Exemple : Extraction de liens (1)

- Extraction des adresses de liens dans une page HTML

  Retrouver la valeur de l'attribut `href` des éléments `a`

  Utilisation du motif `<a.*href="(.*)".*>`

```
1  pattern = r'<a.*href="(.*)".*>'
2  p = re.compile(pattern, re.MULTILINE)
3
4  for m in p.finditer('''<a href="http://www.google.be" rel="popup"
   class="extlink">
5  <a target="_blank" href="http://www.yahoo.be" class="extlink" rel="
   popup">
6  <a href="http://www.alltheweb.com">'''):
7      print(m.group(1))
```

```
http://www.google.be" rel="popup" class="extlink
http://www.yahoo.be" class="extlink" rel="popup
http://www.alltheweb.com
```

Exemple : Extraction de liens (2)

- Solution 1 : Ne pas capturer " dans l'URL

  Utilisation du motif `<a.*href="([^"]*)".*>`

- Solution 2 : Utilisation des quantificateurs non greedy

  Capturent le moins possible (ajout d'un ? derrière)

```
1  pattern = r'<a.*href="(.*?)".*>'
2  p = re.compile(pattern, re.MULTILINE)
3
4  # ...
```

```
http://www.google.be
http://www.yahoo.be
http://www.alltheweb.com
```

Référence en arrière

- On peut faire référence à un groupe précédemment capturé

  \ *suivi du numéro du groupe*

- Permet par exemple la recherche de répétitions de mot

  Capture d'un mot suivi de blancs (\s) et du même mot

```
1  p = re.compile(r'([a-z]+)\s+\1')
2  m = p.search('Il a une une pomme')
3  if m is not None:
4      print(m.group())
```

```
une une
```

Découpe de chaine

- La méthode `split` découpe une chaine selon un motif

  Permet d'avoir une expression régulière comme séparateur

```
1  pattern = r'[ ,;.?!-]+'
2  p = re.compile(pattern)
3
4  words = p.split('Bonjour ! Comment allez-vous ?')
5  print(words)
```

```
['Bonjour', 'Comment', 'allez', 'vous', '']
```

Liens

- **RegexLib**, http://www.regexlib.com/

  Recueil d'expressions régulières

- **Regex 101**, https://regex101.com/

  Testeur en ligne d'expressions régulières

- **Regex Crossword**, https://regexcrossword.com/

  Jeu en ligne pour apprendre les expressions régulières

Crédits

- https://www.flickr.com/photos/b-tal/151881566
- https://www.flickr.com/photos/strathmeyer/7200873702